


# GridLoad Intelligence BR

Plataforma de Ciência de Dados para Previsão, Monitoramento e Alerta da Demanda Elétrica Brasileira

## 1. Ideia do projeto

O GridLoad Intelligence BR será uma plataforma de Ciência de Dados aplicada ao sistema elétrico brasileiro para analisar o comportamento da carga, prever sua evolução e identificar antecipadamente situações relevantes, como picos de demanda, rampas elevadas e comportamentos fora do padrão.

A camada final será o GridAlert, responsável por transformar os resultados dos modelos em um estado simples e interpretável:



O projeto continua sendo principalmente de Ciência de Dados e Machine Learning. O GridAlert é apenas a camada que transforma os resultados técnicos em algo útil para apoio à decisão.

## 2. Problema

A demanda elétrica varia continuamente ao longo do dia.

Existem:

- períodos de carga baixa;
- horários de pico;
- aumentos rápidos de demanda;
- quedas rápidas;
- dias com comportamento fora do habitual;
- efeitos relacionados a temperatura, horário, dia da semana e sazonalidade.

Observar apenas a carga atual não responde perguntas como:

*Qual será a demanda nas próximas horas?*

*Estamos caminhando para um pico incomum?*

*A carga está aumentando mais rapidamente que o habitual?*

*O comportamento atual está diferente do que seria esperado?*

*Qual período merece maior atenção?*

O GridLoad pretende responder essas perguntas.

### 3. Objetivo geral

*Desenvolver uma plataforma de Ciência de Dados capaz de analisar e prever a demanda elétrica brasileira, antecipar picos e rampas de carga, identificar comportamentos anormais e consolidar essas informações em um sistema inteligente de alertas para apoio ao monitoramento da rede.*

### 4. Objetivos específicos

1. Construir um dataset histórico de carga elétrica utilizando dados reais brasileiros.
2. Analisar padrões horários, semanais e sazonais da demanda.
3. Integrar informações meteorológicas relevantes.
4. Desenvolver modelos de previsão para diferentes horizontes.
5. Detectar antecipadamente períodos de pico.
6. identificar rampas elevadas de carga.
7. Detectar comportamentos anormais.
8. Avaliar a contribuição das informações meteorológicas para os modelos.
9. Utilizar explicabilidade para compreender as previsões.
10. Desenvolver o GridAlert, consolidando os resultados dos modelos em estados interpretáveis.
11. Criar um dashboard para exploração e acompanhamento dos resultados.

### 5. Fontes de dados

#### ONS

Será a principal fonte.

#### Curva de carga

Dados de carga elétrica por:

```
timestamp
subsistema
carga_MW
```

Subsistemas:

```
Norte
Nordeste
Sul
Sudeste/Centro-Oeste
```

Eu começaria por um único subsistema, provavelmente Nordeste ou Sudeste/Centro-Oeste.

Depois, se o projeto estiver estável, ampliaria.

#### INMET

Variáveis meteorológicas, principalmente:

```
temperatura
umidade
precipitação
```

Temperatura deve ser a primeira variável meteorológica estudada.

Não colocaria 15 variáveis climáticas apenas porque estão disponíveis.

#### Calendário

Features derivadas:

```
hora  
dia da semana  
fim de semana  
mês  
feriado
```

## 6. Dataset final

Uma estrutura aproximada:

```
timestamp  
subsystem  
load_mw  
  
temperature  
humidity  
  
hour  
weekday  
month  
is_weekend  
is_holiday  
  
load_lag_1h  
load_lag_2h  
load_lag_3h  
load_lag_24h  
load_lag_48h  
load_lag_168h  
  
rolling_mean_3h  
rolling_mean_6h  
rolling_mean_24h  
rolling_std_6h  
  
ramp_1h  
  
target_load_1h  
target_load_6h  
target_load_24h  
  
peak_next_3h  
high_ramp_next_3h
```


## 7. Módulo 1 — EDA

Antes de qualquer modelo, entender a carga.

Análises principais:

- evolução histórica;
- curva média por hora;
- diferenças entre dias úteis e finais de semana;
- comportamento por mês;
- distribuição da carga;
- horários mais comuns de pico;
- rampas positivas e negativas;
- relação com temperatura;
- autocorrelação;
- comparação entre  $t$ ,  $t-24h$  e  $t-168h$ .

Exemplo:



O EDA será importante também para definir o que significa pico e rampa elevada.

## 8. Módulo 2 — Load Forecast

Será o núcleo preditivo.

### Horizontes

Eu usaria:

$$t+1h$$

$$t+6h$$

$$t+24h$$

Isso permite comparar previsão de curto prazo com previsão do dia seguinte.

### Baseline

Primeiro:

### Persistence

$$\hat{L}(t+1) = L(t)$$

ou:

$$\hat{L}(t) = L(t-24h)$$

O modelo de ML precisa superar esses baselines.

### Modelos

Não faria uma competição com 15 algoritmos.

Usaria:

Linear Regression  
↓  
XGBoost ou LightGBM

e talvez:

Random Forest

como comparação.

Deep Learning ficaria fora do MVP.

## 9. Features temporais

Aqui deve estar uma parte importante do trabalho.

## Lags

```
load_lag_1h  
load_lag_2h  
load_lag_3h  
load_lag_24h  
load_lag_48h  
load_lag_168h
```

168h = uma semana.

## Rolling

```
mean_3h  
mean_6h  
mean_24h  
  
std_3h  
std_6h
```

## Calendário

```
hour  
weekday  
month  
weekend  
holiday
```

Para hora, inclusive poderíamos usar encoding cíclico:

$$hour\_sin = \sin(2\pi h/24)$$

$$hour\_cos = \cos(2\pi h/24)$$

## 10. Módulo 3 — Peak Intelligence

Não queremos apenas descobrir:

| Carga às 19h = 47 GW

Queremos saber:

| *Essa carga representa um pico relevante?*

Uma abordagem simples seria utilizar percentis históricos.

Por exemplo:

```
< P90      → normal  
P90–P97    → elevado  
≥ P97      → muito elevado
```

Os valores exatos seriam definidos após analisar os dados.

## Problema de ML

Target:

```
peak_next_3h  
  
0 = não  
1 = sim
```

Entrada:

```
carga_atual  
lags  
médias_móveis  
temperatura  
hora  
dia
```

Saída:

Probabilidade de pico  
nas próximas 3 horas:

 82%

## 11. Módulo 4 — Ramp Intelligence

Uma rampa mede quanto a demanda mudou.

$$Ramp\_t = L\_t - L\_(t-1)$$

Exemplo:

|     |           |
|-----|-----------|
| 17h | 40.000 MW |
| 18h | 41.200 MW |
| 19h | 44.000 MW |

Logo:

$$Ramp\_19h = +2800 \text{ MW/h}$$

O objetivo será identificar:

| *Estamos caminhando para uma variação excepcionalmente rápida da carga?*

### Ramp Risk

Podemos usar novamente percentis históricos.

|            |               |
|------------|---------------|
| Ramp < P90 | NORMAL        |
| P90–P97    | ELEVADA       |
| > P97      | MUITO ELEVADA |

E eventualmente criar:

| high\_ramp\_next\_3h = 0/1

para classificação antecipada.

## 12. Módulo 5 — Anomaly Detection

Aqui eu faria uma versão propositalmente simples.

O próprio forecast estabelece qual seria aproximadamente o comportamento esperado.

Calculamos:

$$Residual\_t = Load\_real,t - Load\_previsto,t$$

Exemplo:

|          |           |
|----------|-----------|
| Previsto | 38.500 MW |
| Real     | 43.200 MW |
| Residual | +4.700 MW |

Um residual muito acima do comportamento histórico indica situação incomum.

### Anomaly Score

Algo como:

|      |                        |
|------|------------------------|
| 0.12 | → comportamento normal |
| 0.47 | → incomum              |
| 0.91 | → fortemente anormal   |

Podemos começar apenas com estatística dos resíduos.

Se houver tempo:

| Isolation Forest

como extensão.

Não faria Autoencoder.

## 13. Módulo 6 — Weather Intelligence

Não será outro sistema independente.

O objetivo é responder:

| *Meteorologia melhora a previsão da demanda?*

Experimento:

### Modelo A

histórico da carga  
+  
calendário

### Modelo B

histórico da carga  
+  
calendário  
+  
temperatura  
+  
umidade

Depois comparar:

MAE  
RMSE  
MAPE

Isso cria uma conclusão científica objetiva.

## 14. Sensibilidade à temperatura

Também podemos investigar:

$$Load = f(Temperature)$$

Separando, por exemplo:

manhã  
tarde  
noite

ou:

dias úteis  
fim de semana

Sem assumir previamente que temperatura necessariamente aumenta ou reduz a carga.

Os dados responderão.

## 15. Módulo 7 — Explainable AI

Aqui entra SHAP.

Quando o modelo prevê:

Carga +6h:  
45.830 MW

podemos mostrar:

Carga t-1h  
Carga t-24h  
Hora  
Temperatura  
Carga t-168h  
Fim de semana



Também poderemos analisar globalmente:

| *Quais features são mais importantes para prever carga?*

E localmente:

| *Por que essa previsão específica ficou tão alta?*

## 16. Módulo 8 — GridAlert

Esse será o componente final do produto.

Não é outro modelo complexo.

Ele recebe:

Forecast  
+  
Peak Risk  
+  
Ramp Risk  
+  
Anomaly Score

e produz uma interpretação única.

## 17. Estados do GridAlert

Eu inicialmente utilizaria três:

### NORMAL

Carga dentro do comportamento esperado.  
Sem pico significativo previsto.  
Sem rampa elevada.  
Sem anomalia relevante.

### ATENÇÃO

Algum indicador importante está elevado.

Exemplo:

Peak Risk = alto  
ou  
Ramp Risk = alto

### CRÍTICO

Combinação de condições excepcionalmente elevadas.

Por exemplo:

Peak Risk = muito alto  
+  
Ramp Risk = muito alto

ou outra combinação definida experimentalmente.

Eu evitaria chamar qualquer condição comum de “crítica”; os limites devem ser bem justificados pelos dados.

## 18. Exemplo de regra

Uma primeira versão poderia ser:

```
if peak_risk < 0.5 and ramp_risk < 0.5:
    status = "NORMAL"

elif peak_risk >= 0.8 and ramp_risk >= 0.8:
    status = "CRITICO"

else:
    status = "ATENCAO"
```

Depois refinamos com base nos resultados.

Não há necessidade de treinar outro modelo apenas para produzir o alerta.

## 19. O alerta precisa explicar o motivo

Isso é importante.

Não basta:

| △ ATENÇÃO

O sistema deverá produzir:

```
GRIDALERT
-----

STATUS
ATENÇÃO

Período:
18h–20h

Motivos:

• Pico previsto acima do P95 histórico.
• Rampa prevista de +2.480 MW/h.
• Temperatura acima da média do período.

Anomaly Score:
Normal
```

Assim o usuário sabe por que recebeu o alerta.

## 20. GridAlert não deve dar ordens ao sistema

Eu manteria essa distinção explícita.

Ele não dirá:

| “ligue determinada usina”.

ou:

| “reduza 800 MW imediatamente”.

Ele fará:

| *classificação e priorização das condições previstas.*

Exemplo:

NORMAL  
→ acompanhamento usual

ATENÇÃO  
→ período merece acompanhamento ampliado

CRÍTICO  
→ combinação incomum de pico/rampa prevista

Isso deixa o projeto tecnicamente responsável e não exige conhecimento de operação real do SIN que está fora do seu escopo.

## 21. Exemplo completo

Imagine:

SUBSISTEMA  
Nordeste

Agora  
16:00

Carga atual  
12.810 MW

Forecast:

|     |           |
|-----|-----------|
| 17h | 13.100 MW |
| 18h | 13.750 MW |
| 19h | 14.620 MW |
| 20h | 14.480 MW |
| 21h | 13.900 MW |

Sistema calcula:

Peak probability  
87%

Peak esperado  
19:00

Ramp máxima  
+870 MW/h

Ramp percentile  
P96

Anomaly score  
0.17

GridAlert:

| GRIDALERT                                                                                                                                                                                                                  |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| STATUS<br>ATENÇÃO<br><br>PERÍODO MAIS RELEVANTE<br>18:00–20:00<br><br>PEAK RISK<br>ALTO – 87%<br><br>RAMP RISK<br>ALTO – P96<br><br>ANOMALY<br>NORMAL<br><br>MOTIVO<br>Pico e rampa elevados<br>previstos simultaneamente. |

Esse é o produto.

## 22. Dashboard

Eu faria três páginas.

### Overview

|               |
|---------------|
| Carga atual   |
| Forecast 24h  |
| Peak Risk     |
| Ramp Risk     |
| Anomaly Score |
| GridAlert     |

### Analytics

Gráficos de:

|                     |
|---------------------|
| histórico           |
| real × previsto     |
| erro do modelo      |
| temperatura × carga |
| rampas              |
| picos históricos    |
| SHAP                |

### Alerts

Histórico:

| Data  | Status  | Motivo      |
|-------|---------|-------------|
| 15/09 | Normal  | —           |
| 16/09 | Atenção | Peak        |
| 17/09 | Atenção | Ramp        |
| 18/09 | Crítico | Peak + Ramp |

E detalhes de cada evento.

## 23. Validação temporal

Essa será uma parte importante do projeto.

Nada de:

```
train_test_split(shuffle=True)
```

A separação precisa respeitar o tempo.

Por exemplo:



Ou:

```

TRAIN
2022–2024

VALIDATION
2025

TEST
2026
  
```

Dependendo da quantidade e qualidade dos dados.

## 24. Métricas

### Forecast

```

MAE
RMSE
MAPE
  
```

### Peak/Ramp

Como provavelmente haverá desbalanceamento:

```

Precision
Recall
F1
PR-AUC
  
```

Accuracy não será suficiente.

### GridAlert

Podemos avaliar quantos períodos relevantes foram sinalizados antecipadamente.

Também:

### False Alert Rate

$$\text{alertas indevidos} / \text{total de alertas}$$

### Lead Time

Quanto antes do pico/rampa o alerta foi emitido.

Exemplo:


GridAlert:  
16:00

Pico:  
19:00

Lead Time:  
3 horas

Essa seria uma ótima métrica final.

## 25. Arquitetura final



## 26. Tecnologias

Eu manteria enxuto:

### Dados

Python  
Pandas  
NumPy

### ML

Scikit-learn  
XGBoost ou LightGBM  
SHAP

### Visualização

Matplotlib  
Plotly

## Produto

| Streamlit

## Opcional

| PostgreSQL  
| FastAPI  
| Docker

Não faria FastAPI/PostgreSQL inicialmente.

Primeiro faça o modelo funcionar.

## 27. Estrutura do repositório

Algo como:

```
gridload-br/
├── data/
│   ├── raw/
│   ├── interim/
│   └── processed/
├── notebooks/
│   ├── 01_data_inventory.ipynb
│   ├── 02_data_cleaning.ipynb
│   ├── 03_eda.ipynb
│   ├── 04_feature_engineering.ipynb
│   ├── 05_forecasting.ipynb
│   ├── 06_peak_intelligence.ipynb
│   ├── 07_ramp_intelligence.ipynb
│   ├── 08_anomalies.ipynb
│   └── 09_explainability.ipynb
├── src/
│   ├── data/
│   ├── features/
│   ├── models/
│   └── alerts/
├── models/
├── dashboard/
├── reports/
├── requirements.txt
└── README.md
```

## 28. Cronograma de três meses

### Semanas 1-2

Dados

- ONS;
- INMET;
- inventário;
- limpeza;
- sincronização.

### Semanas 3-4

EDA + Features

- comportamento da carga;

- rampas;
- picos;
- lags;
- rolling features;
- meteorologia.

#### Semanas 5-6

Forecast

- baseline;
- XGBoost/LightGBM;
- validação temporal;
- +1h/+6h/+24h.

#### Semana 7

Peak Intelligence

#### Semana 8

Ramp Intelligence

#### Semana 9

Anomaly Detection + Weather Intelligence

#### Semana 10

SHAP + interpretação

#### Semana 11

GridAlert

#### Semana 12

Dashboard + documentação + refinamentos

Isso é um escopo bastante razoável para uma pessoa.

## 29. MVP obrigatório

Se o tempo apertar, considero essenciais somente:

```

ONS + INMET
  ↓
EDA
  ↓
Forecast 1h / 6h / 24h
  ↓
Peak Intelligence
  ↓
Ramp Intelligence
  ↓
GridAlert
  ↓
Dashboard

```

Esses elementos já formam um projeto completo.

## 30. Funcionalidades complementares

Entrariam apenas se o MVP estiver pronto:

- anomaly detection mais sofisticado;
- SHAP detalhado;
- múltiplos subsistemas;

- previsão automática diariamente;
- API;
- PostgreSQL;
- Docker;
- histórico de alertas;
- atualização automática dos dados.

## **31. O que deliberadamente fica fora**

Para impedir que o projeto volte a ficar grande demais:

não teremos:

- Grid Balance Intelligence;
- previsão de geração solar/eólica;
- clustering de regimes;
- change point detection;
- despacho de geração;
- otimização de bateria;
- demand response;
- fluxo de potência;
- otimização do SIN;
- controle real da rede;
- Deep Learning obrigatório.

Isso é importante para proteger o escopo.

## **32. Resultado esperado**

O GridLoad deverá conseguir receber uma determinada janela temporal e responder algo semelhante a:

## GRIDLOAD INTELLIGENCE BR

Subsistema:  
NORDESTE

Carga atual:  
12.840 MW

Forecast:  
+1h 13.020 MW  
+6h 14.310 MW  
+24h 12.970 MW

Peak Intelligence:  
82% – ALTO

Peak esperado:  
19:00

Ramp Intelligence:  
+920 MW/h – ELEVADA

Anomaly:  
NORMAL

GRIDALERT:  
△ ATENÇÃO

Período relevante:  
18:00–20:00

Motivo:  
Pico e rampa elevados  
previstos simultaneamente.

Esse é um resultado final fácil de explicar e demonstrar.

## 33. Impacto

O diferencial não será simplesmente:

“fiz um modelo para prever consumo de energia.”

Será:

“desenvolvi uma plataforma que utiliza dados públicos reais do sistema elétrico brasileiro para transformar séries temporais de demanda e meteorologia em previsões, identificação antecipada de picos e rampas e alertas interpretáveis sobre o comportamento futuro da carga.”

Isso demonstra:

Data Engineering → EDA → séries temporais → feature engineering → regressão → classificação → anomaly detection → explainable AI → aplicação.

Sem exigir que você se torne engenheiro eletricista para conseguir concluir o projeto.

## Nome e descrição final

### GridLoad Intelligence BR

Plataforma Inteligente de Previsão e Alerta da Demanda Elétrica Brasileira

Sistema de Ciência de Dados desenvolvido com dados reais do Sistema Interligado Nacional para previsão da carga elétrica, antecipação de picos e rampas de demanda, análise de comportamentos atípicos e geração de alertas interpretáveis através do módulo GridAlert, utilizando Machine Learning, séries temporais, dados meteorológicos e Explainable AI.

Essa é a versão que eu consideraria como escopo fechado do projeto de três meses.